



DOCUMENTO TÉCNICO

Inteligência da Plataforma Mandor

Como uma arquitetura de IA auditável transforma documentos em análises institucionais confiáveis — e em originação de deals.

Sumário executivo

A Mandor é uma plataforma de **análise institucional de operações** (crédito estruturado, M&A e captação) construída sobre um time de **agentes de IA auditáveis**. A tese central de engenharia é simples e exigente: *uma análise institucional não pode alucinar*. Por isso a inteligência da plataforma não é "um modelo respondendo perguntas" — é uma **arquitetura em camadas** que lê 100% da documentação, extrai fatos rastreáveis, raciocina em múltiplos agentes especializados, e submete tudo a verificações determinísticas antes de qualquer conclusão chegar ao usuário.

Este documento descreve, de ponta a ponta, **toda a inteligência da plataforma**: a ingestão de documentos, o time de agentes, as camadas de confiabilidade que previnem erros, o controle humano sobre o processo, o motor de originação InvestMatch e a economia de custo que torna tudo viável.

Princípios de design:

1. **Confiabilidade acima de fluência** — preferimos uma análise que admite uma lacuna a uma que inventa um número.
2. **Tudo rastreável** — cada afirmação crítica aponta para o documento, a página e a citação que a sustentam.
3. **Decisão final humana** — a IA estrutura, evidencia e alerta; o assessor decide.
4. **Custo sob controle** — leitura integral dos documentos sem explosão de custo, via cache, modelos certos para cada tarefa e processamento assíncrono.

Parte I — Visão geral da arquitetura

O ciclo completo de uma análise percorre seis estágios:

1. **Ingestão inteligente** — documentos são lidos integralmente (incluindo PDFs escaneados via OCR), fatiados, indexados semanticamente e convertidos em **fatos estruturados**.
2. **Consolidação de fatos** — os fatos de todos os documentos são deduplicados, padronizados e checados por conflito, formando o *fact bank* — a base de verdade da análise.
3. **Análise multiagente** — 14 agentes especializados raciocinam em ondas, lendo as saídas uns dos outros.
4. **Verificação de confiabilidade** — Truth Layer, benchmarks, claims, motor de consistência, sentinela de riscos, mesa consolidadora e validador de cobertura.
5. **Controle humano** — regeneração assistida com revisor de IA, cascata de impacto e auditoria completa.
6. **Originação (InvestMatch)** — a análise vira uma tese viva que é cruzada com a base de investidores.

Os dois cérebros: Sonnet 4.6 e Haiku 4.5

A plataforma usa dois modelos Claude, cada um onde rende mais:

Modelo	ID	Usado para
Claude Sonnet 4.6	claude-sonnet-4-6	Raciocínio financeiro profundo: orquestração, pesquisa, diagnóstico, M&A, estruturação, maturidade, consolidação de fatos, mesa, sentinela, juiz de matching
Claude Haiku 4.5	claude-haiku-4-5-20251001	Tarefas estruturadas e de alto volume: extração de fatos por trecho, validação de cobertura, revisor de regeneração, detetive de dependências

Extended Thinking (raciocínio estendido, orçamento de 8.000 tokens) é ativado nos três passos mais analíticos: **diagnóstico**, **análise M&A** e **estruturação**.

Prompt caching — o que torna o custo viável

Blocos de instrução estáveis (a diretriz de escrita, a camada de verdade, os benchmarks, a diretriz de claims) são marcados com cache de 1 hora. A primeira chamada "escreve" o cache; as seguintes o "leem" a ~10% do custo. Como o pipeline de uma análise leva de 10 a 20 minutos, o cache permanece quente do início ao fim — e várias análises no mesmo período compartilham o mesmo cache.

Parte II — Ingestão inteligente de documentos

O maior risco de custo e de erro está na entrada: dossiês com dezenas de documentos e centenas de páginas. A Mandor resolve isso com um **pipeline assíncrono map-reduce** orquestrado por **Inngest**, que lê **100% dos documentos** sem truncar conteúdo.

Fluxo

- Disparo** (`POST /api/analise/[id]/ingest`) — lista os arquivos do storage (até 200 por análise), cria um registro por documento e dispara **N eventos paralelos** (um por documento). A resposta é imediata; o trabalho roda em segundo plano.
- Processamento por documento** (até **4 documentos simultâneos**, com 3 tentativas automáticas):
 - Extração de texto** conforme o tipo: PDF nativo (camada de texto), **OCR Mistral** (`mistral-ocr-latest`) para PDFs escaneados e imagens, Mammoth para DOCX, XLSX para planilhas, UTF-8 para texto.
 - Chunking semântico** — alvo de ~30 mil tokens por trecho, com sobreposição de ~2 mil tokens para preservar contexto, quebrando em fronteiras naturais (parágrafo, frase).
 - Embeddings** — cada trecho é vetorizado com **voyage-3-large (1.024 dimensões)**, modelo multilíngue otimizado para português, armazenado em **pgvector** com índice **HNSW** (m=16, ef_construction=64).
 - Extração de fatos por trecho** — **Claude Haiku 4.5** converte cada trecho em fatos estruturados em JSON (temperatura 0), com tipo, chave, valor, citação literal, página e confiança.
- Consolidação** — quando todos os documentos terminam, o **Consolidador (Claude Sonnet 4.6)** processa os fatos em **lotes de 40 por tipo**, deduplicando entradas idênticas, padronizando unidades

(ex.: "R\$ 2,3 mi" e "2.300.000 BRL" viram um único valor canônico em BRL) e **marcando conflitos** entre documentos.

4. **Fact bank** — o resultado consolidado é gravado na análise (~30 mil tokens compactos), substituindo a releitura bruta de centenas de páginas.

Detecção de conflitos entre documentos

Na consolidação, valores divergentes para o mesmo fato (ex.: data de fundação 1990 em um documento e 1995 em outro) geram uma entrada com `status = conflict`, preservando **todas as variantes com suas fontes** e reduzindo a confiança ao mínimo entre elas. Em um teste real (38 documentos, 29,7 MB), o pipeline extraiu 340 fatos brutos, consolidou em 86 (75% de deduplicação) e detectou **7 conflitos cross-documento** automaticamente — divergências de datas de CNPJ, áreas de imóvel e endereços de sede.

RAG sob demanda

Quando um agente precisa de um detalhe específico, ele não relê os PDFs: faz uma busca semântica (`match_document_chunks`) que devolve os trechos mais relevantes por similaridade de cosseno (padrão: 8 trechos, similaridade mínima 0,4). Leitura cirúrgica, custo mínimo.

Parte III — O time de agentes de análise

O núcleo da plataforma é um time de **14 agentes especializados**, cada um com um papel definido e um prompt versionado e editável (sem necessidade de deploy) pela administração.

#	Agente (apelido)	Papel
0	Ingestão de Dados	Lê os documentos e produz um diagnóstico documental (o que foi lido, qualidade, lacunas).
1	Orquestrador (Otto Orquestra)	Calcula o Deal Readiness Score (DRS), diagnostica aptidão inicial e mapeia riscos.
2	Pesquisa (Pedro Panorama)	Inteligência de mercado: benchmarks setoriais, múltiplos de transação, posição competitiva, timing.
3	Diagnóstico (Davi Diagnóstico)	Saúde financeira: demonstrações, normalização de EBITDA, valuation preliminar, estrutura de capital.
4	KYC & Compliance (Carmen Compliance)	Screening regulatório, KYC de sócios/PEP, red flags e conformidade CADE.
5	Contratos (Clara Cláusula)	Riscos jurídicos, estrutura societária, passivos contingentes, contratos críticos.
6	Arquiteto M&A (Arthur Aquisição)	Tese de M&A, compradores estratégicos, estrutura da transação e negociação.
7	Originação (Victor Valor)	Posicionamento comercial, perfil de comprador-alvo e pipeline de originação.
8	Estruturação (Estela Estrutura)	Operações de capital e crédito estruturado adequadas (FIDC, CRI, debêntures, PE).
9	Maturidade (Paulo Preparo)	Veredicto de maturidade (Apto / Apto com ajustes / Não apto) e roadmap de preparação.
10	Revisão (legado)	Coerência narrativa entre agentes — hoje incorporado ao relatório consolidado.
11	Blind Teaser	Documento anônimo de 1-2 páginas, padrão ANBIMA, para distribuição inicial.
12	Sell-Side Pitchbook	Information Memorandum completo (pós-NDA), padrão ANBIMA/ICVM.
13	Relatório Consolidado	Síntese cross-dimensional, contradições, bloqueantes e recomendação executiva.

Execução em ondas

Os agentes não rodam em fila linear — rodam em **ondas**, com paralelismo onde é seguro:

- **Onda 1** — Ingestão → Orquestração (sequencial; formam o contexto compartilhado e cacheado).
- **Onda 2** — Pesquisa, Diagnóstico, KYC, Contratos, M&A, Originação, Estruturação (**em paralelo**).
- **Onda 3** — Maturidade (lê tudo o que veio antes).
- **Onda 4** — Blind Teaser + Pitchbook (**em paralelo**).

- **Onda 5** — Relatório Consolidado.

Leitura cruzada (cross-reading)

Para conectar riscos entre dimensões, agentes da Onda 2 leem as saídas uns dos outros segundo um mapa de dependências:

- **Análise M&A** lê: Diagnóstico, Contratos, Pesquisa.
- **Estruturação** lê: Diagnóstico, Pesquisa.
- **Originação** lê: Pesquisa, Diagnóstico, Contratos.
- **Maturidade** lê: todas as saídas anteriores.

Estilo institucional

Uma diretriz de escrita compartilhada por todos os agentes (cacheada para custo zero recorrente) proíbe linguagem de "IA genérica" (palavras-clichê, hedging excessivo, emojis) e exige terminologia financeira técnica, posição clara quando os dados sustentam e foco no "porquê", não no "o quê".

Parte IV — Arquitetura de confiabilidade

Esta é a camada que diferencia a Mandor de uma "IA genérica". São sete mecanismos que, juntos, tornam a análise auditável e resistente a alucinação.

1. Truth Layer (camada de verdade)

Os fatos extraídos dos documentos são consolidados e **injetados como verdade absoluta** no prompt de todos os agentes (exceto o de ingestão, que é a fonte). São oito tipos de fato: documento disponível, número financeiro, estrutura societária, contrato, garantia, passivo, evento relevante e **lacuna** (o que era esperado e não foi encontrado).

Cada fato carrega `source_doc`, `source_page`, `source_quote` e `confidence` (0–1). E há **regras absolutas** codificadas (chamadas internamente de *ERRO_FATO*):

- Afirmar que um documento está ausente quando ele consta no fact bank → erro.
- Citar um número financeiro diferente do consolidado sem justificar com nova fonte → erro.
- Recomendar uma ação que depende de documento ausente sem sinalizar a lacuna → erro.

2. Benchmark Registry (parâmetros de mercado)

Um registro versionado de parâmetros de referência por instrumento — **FIDC, CRI, CRA, CCB, debêntures, M&A e crédito bancário** — com faixas (mín/máx), unidade e fonte (ex.: ticket mínimo de FIDC, múltiplos EV/EBITDA setoriais, cobertura de juros). É injetado nos agentes de estruturação, M&A, pesquisa, originação e maturidade.

A função de **elegibilidade** bloqueia recomendações impossíveis: sugerir um FIDC para um ticket abaixo do mínimo viável gera uma violação. Cada escritório pode **sobrescrever** benchmarks globais para a própria realidade (com trava de versão para evitar edições simultâneas conflitantes) — o override vence o global apenas no parâmetro alterado.

3. Structured Claims (afirmações auditáveis)

Ao final de cada análise, **10 agentes** emitem um bloco invisível de "claims": cada afirmação crítica é declarada com tipo (número, fato, recomendação, risco, avaliação), os fatos e benchmarks que a sustentam, uma citação opcional e um nível de confiança. O bloco é removido do texto final e **persistido** para auditoria — é a matéria-prima do motor de consistência.

4. Consistency Engine (motor de consistência)

Determinístico — não usa IA. Aplica regras concretas sobre os claims, com tolerância numérica de **1%**:

- **Número divergente** — claim que contradiz o fact bank.
- **Número entre agentes** — dois agentes citam o mesmo fato com valores diferentes.
- **Benchmark violado** — recomendação cujo número sai da faixa do benchmark citado.
- **Lacuna crítica** — conclusão apoiada em um fato do tipo "lacuna".
- **Recomendação sem fonte** — recomendação sem nenhum fato ou benchmark de respaldo.

As inconsistências são classificadas como **bloqueante** ou **alerta** e exibidas em painel próprio.

5. Sentinela de riscos

Um agente (Sonnet 4.6) que roda após todos os especialistas e busca **síndromes cross-dimensionais** — combinações de riscos que, isolados, parecem inofensivos, mas juntos formam um padrão sistêmico (ex.: covenant apertado + saída de sócio + caixa curto = distribuição disfarçada). Parcimonioso por design: aponta de 0 a 4 síndromes por deal.

6. Mesa Consolidadora

O **revisor final institucional**, no tom de um diretor de crédito sênior revisando o material que iria a comitê. Emite um veredito — **aprovado / aprovado com ressalvas / revisão necessária** — com diagnóstico final, pontos fortes e fracos, contradições detectadas e recomendação ao assessor.

7. Coverage Validator (validador de cobertura)

Garante que nada essencial ficou de fora. Há **checklists obrigatórios por tipo de operação**, detectado automaticamente a partir do objetivo do deal:

Tipo de operação	Itens
FIDC	12
M&A (venda)	10
M&A (captação)	8
Crédito bancário	8
Geral (fallback)	6

Cada item é avaliado como **coberto** (com profundidade e números), **parcial** (mencionado sem profundidade) ou **não coberto** — e, para os não cobertos, a plataforma indica qual agente é responsável e

oferece regeneração dirigida.

Dados regulatórios e de mercado

A análise é enriquecida com fontes oficiais em tempo real:

- **Banco Central (BCB)** — SELIC, IPCA, câmbio PTAX e PIB, injetados nos agentes de pesquisa e estruturação.
- **CVM** — emissões recentes de debêntures, CRI e CRA e empresas abertas comparáveis (cache de 24h), para benchmarking de mercado.
- **CADE** — verificação automática de obrigatoriedade de notificação concorrencial (Lei 12.529/2011): faturamento do grupo adquirente $\geq$ R\$ 750 mi e do alvo $\geq$ R\$ 75 mi. A análise classifica a operação em obrigatória / provável / não obrigatória e injeta o alerta no agente de KYC.

Parte V — Controle humano: regeneração e cascata

A IA não tem a palavra final — o assessor tem. E o processo de revisão também é assistido por IA:

- **Regeneração assistida** — ao pedir para refazer um trecho da análise, o assessor escreve um briefing (o quê e por quê). O **Revisor** (Haiku 4.5, temperatura 0) avalia se o pedido faz sentido técnico antes de executar — mas, mesmo quando contra-argumenta, a decisão final é sempre humana (compatível com a ICVM 598/2018).
- **Cascata de impacto** — depois de refazer um trecho, o **Detetive de Dependências** compara as versões e identifica quais outros agentes ficaram inconsistentes, sugerindo (com severidade alta/média/baixa) o que reprocessar.
- **Auditoria** — cada passo executado é registrado com modelo, tokens, duração e contexto usado; cada regeneração guarda o briefing, o argumento da IA e os riscos apontados. A trilha completa fica disponível em painel administrativo.

Parte VI — InvestMatch: originação inteligente

A análise consolidada não termina em um relatório — ela vira uma **tese viva** que é cruzada com a base de investidores do escritório. O InvestMatch é um motor de matching de **cinco camadas**.

Da análise à tese

O construtor de tese (`thesis-builder` , Sonnet 4.6) combina **mapeamento determinístico** (números extraídos direto do fact bank: receita, EBITDA, capital buscado, valuation) com **extração por IA** dos campos narrativos (tese de investimento, proposta de valor, *moat* competitivo, narrativa de risco, história de saída) e de scores qualitativos (maturidade, governança, solidez operacional).

O `risk_overall_score` é determinístico: parte de uma base e soma penalidades por inconsistências bloqueantes/alertas, pelo veredito da mesa e por contradições semânticas. A tese recebe um **embedding voyage-3-large (1.024d)** que captura sua essência semântica.

As cinco camadas

1. **Hard filter (SQL)** — exclusões categóricas: ticket fora da faixa, setor excluído, geografia incompatível, exigências de ESG/DD não atendidas.
2. **Score estruturado (SQL)** — média ponderada de 10 dimensões:

Dimensão	Peso
Setorial	0,20
Ticket	0,15
Estágio	0,10
Maturidade	0,10
Governança	0,10
Risco	0,10
Documentação	0,10
Geografia	0,05
Horizonte de saída	0,05
Urgência	0,05

3. **Busca semântica (pgvector)** — similaridade de cosseno entre os embeddings da tese e dos investidores (índice HNSW, similaridade mínima 0,3).
4. **Juiz de IA** (`match-judge` , Sonnet 4.6) — só os **20 melhores** candidatos do pré-ranking vão ao juiz, que produz: score de sinergia, resumo, pontos fortes, ressalvas, *talking points* para a primeira reunião, probabilidade de fechamento e uma **recomendação** (strong_match / review / **skip**). Um "skip" **descarta o match mesmo com score alto** — é a trava anti-falso-positivo.
5. **Score composto** — combina as camadas:
 - Com embedding: **0,50 estruturado + 0,20 semântico + 0,30 IA**.
 - Sem embedding: **0,65 estruturado + 0,35 IA** (renormalizado).

Decisão

Score final	Resultado
< 70	Descartado (não persiste)
70–84	Sugerido — aguarda curadoria
≥ 85	Aprovado automaticamente

(Um "skip" do juiz descarta independentemente do score.)

Originação reversa

O motor roda também no sentido inverso — **do investidor para as teses** — com a mesma matemática e papéis trocados (versão `v2.0-reverse`), persistindo na mesma base de matches. Cadastrar um investidor com tese declarada dispara automaticamente a busca de oportunidades aderentes.

Loop de feedback e calibração

Cada match gera aprendizado: avaliações manuais (muito bom → muito ruim) e *outcomes* automáticos (NDA, proposta, due diligence, fechado, abandonado). A plataforma mede a **conversão por faixa de score** e o **poder discriminativo** de cada dimensão (diferença entre a média dos sucessos e a dos fracassos) e **sugere** novos pesos — mas a recalibração é **manual e deliberada** (mistura 30% do dado novo com 70% do peso atual, e exige no mínimo 8 resultados), justamente para evitar overfitting com amostra pequena.

Parte VII — Modelos, custo e infraestrutura

Qual modelo faz o quê

Tarefa	Modelo
Raciocínio analítico (agentes principais)	Claude Sonnet 4.6
Consolidação de fatos	Claude Sonnet 4.6
Sentinela, mesa, juiz de matching, construtor de tese	Claude Sonnet 4.6
Extração de fatos por trecho	Claude Haiku 4.5
Validador de cobertura, revisor, detetive	Claude Haiku 4.5
OCR de documentos escaneados	Mistral OCR
Embeddings (RAG e matching)	voyage-3-large (1.024d)

Como o custo é controlado

A motivação foi concreta: uma análise antiga chegou a custar dezenas de dólares em um único dia por jogar o pipeline em *long-context* (preço dobrado) com cache que expirava antes de ser lido. A redesenho atacou isso em quatro frentes:

- Prompt caching de 1 hora** nos blocos estáveis — reduz drasticamente o custo de input recorrente.
- Modelo certo para cada tarefa** — Haiku (cerca de 3x mais barato) nas tarefas estruturadas de alto volume; Sonnet só onde há raciocínio.
- Batching** — fatos consolidados em lotes de 40; embeddings em lote; busca vetorial indexada (HNSW) em vez de varredura completa.
- Fact bank consolidado** — comprime centenas de páginas em ~30 mil tokens, evitando a releitura bruta dos documentos (a maior fonte de desperdício anterior).

Stack

Camada	Tecnologia
Aplicação	Next.js 16 (App Router), Tailwind v4
Banco de dados	Supabase (PostgreSQL) + pgvector
Processamento assíncrono	Inngest
IA (raciocínio)	Anthropic Claude — Sonnet 4.6 e Haiku 4.5
OCR	Mistral OCR
Embeddings	voyage-3-large (1.024 dimensões)
Pagamentos	Stripe
E-mail	Resend
Hospedagem	Vercel (produção em www.mandor.com.br)

Encerramento

A inteligência da Mandor não está em um único modelo, mas na **orquestração disciplinada** de muitos: agentes que se especializam e se leem, fatos que viajam rastreáveis do documento à conclusão, regras determinísticas que pegam o que a IA deixaria passar, e um motor de originação que transforma a análise em negócio. Tudo desenhado em torno de uma convicção: em finanças institucionais, **confiança não é um recurso — é o produto**.

Documento gerado em 20/05/2026. Os parâmetros descritos (pesos, faixas, modelos) refletem a configuração de produção nesta data e evoluem com a calibração contínua da plataforma.